

Zadanie	1	2	3	4	5	6	7	8	9	10	Σ
Punkty											
(maks)	(2)	(2)	(2)	(2)	(2)	(6)	(6)	(6)	(6)	(6)	(40)

NAZWISKO I IMIĘ:

[illegible]

NR. INDEKSU:

--	--	--	--	--	--

— Czas pisania pracy: 75 minut —

-

☐ a) 1NN jest lepszym klasykatorem niż 3NN (jak zwykle);

☐ b) 1NN jest gorszy niż 9NN;

☐ c) Na tych danych 1NN nie może być lepszy niż jakikolwiek inny klasyfikator;

- ✦
✦ ○

- ☐ a) 3NN;
 - ☐ b) SVM (z jądrem kwadratowym);
 - ☐ c) Dwupoziomowe drzewo decyzyjne (z użyciem cięć na pojedynczych atrybutach)

- ☐ a) k NN (z metryką Euklidesową i dowolnym parametrem k).
 - ☐ b) SVM, jeśli tylko punkty należące do różnych klas są separowalne.
 - ☐ c) AdaBoost.

- | | Prawdziwa decyzja | |
|---------------------------|-------------------|-----------------|
| | <i>spam</i> | <i>not spam</i> |
| $F_1 = \textit{spam}$ | 15 | 15 |
| $F_1 = \textit{not spam}$ | 5 | 65 |

	Prawdziwa decyzja	
	<i>spam</i>	<i>not spam</i>
$F_2 = \textit{spam}$	10	0
$F_2 = \textit{not spam}$	10	80

- ☐ a) $FP(F_1) > FP(F_2)$;
- ☐ b) $TN(F_1) > TN(F_2)$;
- ☐ c) Który z filtrów jest lepszy? Odpowiedź uzasadnij

5. Które z poniższych algorytmów klastrowania nie wymagają znajomości wartości atrybutów poszczególnych obserwacji, a jedynie macierzy odległości między obserwacjami?

- ☐ a) k -Means (algorytm k -centroidów lub k -średnich)
- ☐ b) Grupowanie hierarchiczne z odległością między klastrami *complete linkage* (najbardziej odległe obserwacje).
- ☐ c) SVM.

6. Dany jest zbiór S zawierający 6 punktów na płaszczyźnie (z odległością euklidesową): $a = (0, 0)$, $b = (8, 0)$, $c = (16, 0)$, $d = (0, 6)$, $e = (8, 6)$, $f = (16, 6)$. Chcemy znaleźć 3 klastry za pomocą algorytmu k -means (k -centroidów). Podział zbioru S na trzy klastry nazywamy *początkowym* jeśli jest wyznaczony przez jakiś początkowy układ środków, zaś *stabilnym* jeśli algorytm k -means już nie zmieni tego podziału. Wykonanie algorytmu k -means sprowadza podziały początkowe do jednego z podziałów stabilnych.

- Wyznacz wszystkie podziały stabilne dla S ;

- Dla każdego podziału stabilnego dla S , wyznacz liczbę podziałów początkowych, z których możemy otrzymać ten podział stabilny;

- Jaka jest maksymalna liczba iteracji potrzebna do osiągnięcia podziału stabilnego z podziału początkowego?


7. Rozpatrzmy tablicę decyzyjną dla problemu rozpoznawania grzybów trujących. Obiekty od 1 do 8 są treningowymi, lecz obiekty od 9 do 11 – testowymi.

LP.	ciężki?	śmierdzący?	kropeczki?	gładki?	trujący?
1	0	0	0	0	0
2	0	0	1	0	0
3	1	1	0	1	0
4	1	0	0	1	1
5	0	1	1	0	1
6	1	1	0	0	1
7	0	0	1	1	1
8	0	0	0	1	1
9	1	1	1	1	?
10	0	1	0	1	?
11	1	1	0	0	?

- (a) Chcemy skonstruować drzewo decyzyjne dla tej tablicy. Który test, według Ciebie, powinien być używany w korzeniu drzewa? Odpowiedź uzasadnij

- (b) Policz wszystkie potrzebne rozkłady prawdopodobieństw warunkowych i klasyfikuj obiekty 9, 10 i 11 metodą Naive Bayes.

8. Rozpatrzmy algorytm AdaBoost z użyciem prostych cięć na atrybutach jako słabe klasyfikatory na następującym zbiorze danych:



- (a) Który obiekt będzie miał zwiększoną wagę po pierwszej iteracji?

- (b) Ile iteracji trzeba wykonać, aby osiągnąć zerowy błąd treningowy?

9. (a) Dla funkcji jądrowej $K(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle + 4(\langle \mathbf{x}, \mathbf{y} \rangle)^2$, gdzie \mathbf{x}, \mathbf{y} są wektorami w przestrzeni dwuwymiarowej, znaleźć wartość k oraz odpowiednie zanurzenie $\Phi : \mathbb{R}^2 \rightarrow \mathbb{R}^k$ tak, aby

$$\langle \Phi(\mathbf{x}), \Phi(\mathbf{y}) \rangle = K(\mathbf{x}, \mathbf{y})$$



- (b) Niech $K_1, K_2 : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ będą funkcjami jądrowymi. Udowodnij, że

$$K(\mathbf{x}, \mathbf{y}) = a_1 K_1(\mathbf{x}, \mathbf{y}) + a_2 K_2(\mathbf{x}, \mathbf{y})$$

też jest funkcją jądrową dla dowolnych dodatnich liczb rzeczywistych a_1, a_2 .



10. Niech \mathcal{H}_1 będzie przestrzenią hipotez o wymiarze Vapnika-Chervonenkisa $VCdim(\mathcal{H}_1) = 3$ i niech $\mathcal{H}_2 = \{f_1, \dots, f_k\}$ będzie dowolnym zbiorem klasyfikatorów. Niech $\mathcal{H}_3 = \mathcal{H}_1 \cup \mathcal{H}_2$, oraz niech $m = VCdim(\mathcal{H}_3)$.

- (a) Uzasadnij, że $m < \infty$.



- (b) Udowodnij (np. za pomocą lematu Sauera), że $2^m \leq m^3 + k$.



- (c) Za pomocą oszacowania z (b) znajdź górne ograniczenie dla $VCdim(\mathcal{H}_3)$, gdy $k = 20$.

